AIFFEL | AI DATA INTELLIGENCE

필수 머신러닝

Chapter 1~4 통합 복습

회귀 · 분류 · 전처리 · 데이터 누수 · 교차검증

하나의 분석 과정으로 연결하는 통합 학습 교재

01 전체 지도 · 머신러닝과 X·y

02 회귀 · 오차 · 과적합 · 규제

03 분류 · 확률 · 정밀도 · 재현율

04 전처리 · 파이프라인 · 데이터 누수

05 교차검증 · 실제 집값 프로젝트

06 분석 전체 흐름 · 핵심 인출 · 용어집

AI 데이터 인텔리전스 박근아

머신러닝의 구조부터 회귀·분류·전처리·**데이터 누수**·**교차검증**까지 연결하는 통합 학습자료

이 자료는 필수 머신러닝 Chapter 1~4에서 학습한 개념을 처음부터 끝까지 하나의 분석 과정으로 연결한다. 각각의 개념을 따로 암기하기보다, 실제 문제에서 어떤 역할을 하는지 이해하는 데 초점을 둔다.

가장 중요한 출발점은 다음과 같다.

> **머신러닝은 과거 데이터에서 규칙을 학습해 새로운 데이터를 예측하는 기술이고, 데이터 분석가의 역할은 그 예측이 실제 문제 해결에 쓸 만한지 검증하고 해석하는 것이다.**

이 핵심 원칙은 이후에도 반복된다. 회귀, 분류, 결정 트리, 과적합, 전처리, **파이프라인**, **데이터 누수**, **교차검증**은 모두 이 목적을 달성하기 위해 필요한 개념들이다.

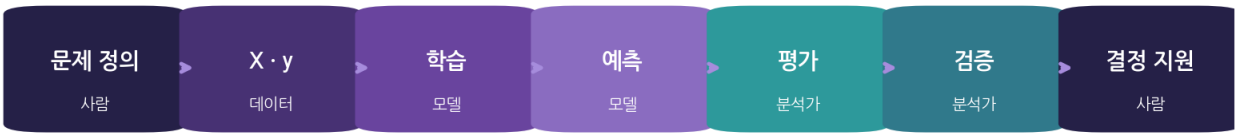
1. 전체 지도: 머신러닝은 무엇이며 왜 필요한가?

AI 데이터 인텔리전스 교육과정에서 머신러닝은 전체 분석 역량을 구성하는 핵심 영역 중 하나다.

머신러닝에 앞서 데이터 수집, 데이터 정리, 탐색적 데이터 분석, 통계, 상관관계와 인과관계 등을 학습한다.

그것들은 주로 **데이터에 무엇이 들어 있는지, 어떤 관계와 패턴이 존재하는지 이해하는 작업**이었다.

머신러닝은 여기에서 한 단계 더 나아간다.



전체 흐름 · 개념 연결을 위한 보조 도식

개념 도식 | 문제 정의부터 의사결정 지원까지의 전체 경로

과거에 관찰된 패턴을 이용해서 아직 정답을 모르는 새로운 사례를 예측한다.

예를 들어 과거의 주택 거래 기록을 분석하는 것은 데이터 분석이다. 어떤 동네의 집값이 높은지, 면적과 집값 사이에 어떤 관계가 있는지, 품질이 가격과 얼마나 강하게 연결되는지 살펴보는 것이다.

그런데 새로운 주택 한 채가 나타났다. 아직 거래되지 않았기 때문에 실제 매매가격을 모른다.

이때 과거의 주택 데이터를 이용해서 이 집은 얼마에 거래될 것 같다고 예측한다면, 그게 바로 머신러닝을 활용한 회귀 분석이다.

은행 고객도 마찬가지이다.

과거 고객들의 정보를 분석해서 어떤 고객들이 정기예금에 가입했는지 확인하는 것은 데이터 분석이다.

그런데 아직 전화하지 않은 새로운 고객이 있다. 이 고객이 정기예금에 가입할 가능성이 높은지 예측한다면 머신러닝을 활용한 분류 분석이 된다.

여기서 두 단어를 기억하자.

> **회귀는 숫자를 예측한다. 분류는 범주를 예측한다.**

집값은 숫자이므로 회귀이다. 가입 여부는 예 또는 아니오라는 범주이므로 분류이다.

이와 달리 군집 분석은 미리 정해진 정답 없이 비슷한 데이터끼리 묶는 비지도학습이다.

즉, 머신러닝 전체를 크게 보면 지도학습과 비지도학습이 있다.

지도학습 안에는 회귀와 분류가 있다. Chapter 1~4에서는 주로 이 두 가지와 모델 검증을 다룬다.

다시 전체 흐름으로 연결해 보자.

> **데이터 분석은 현상을 이해하고, 머신러닝은 학습한 관계를 이용해 예측하며, 검증은 그 예측을 얼마나 믿을 수 있는지 확인하는 작업이다.**

Chapter 1~4는 바로 이 구조를 실제 데이터에 적용하며 구체화하는 과정이다.

2. 머신러닝은 무엇을 학습하는가? X·y·모델

가장 먼저 구분해야 할 기본 기호가 두 개 있다.

X와 y이다.

X는 입력 정보이다. 영어로 **피처**, **Feature**라고 한다. 한국어로는 특성 또는 설명변수라고 부른다.

y는 예측하려는 정답이다. **타깃**, **Target**이라고도 하고 **레이블**, **Label**이라고도 한다.

주택가격 분석에서는 X가 면적, 품질, 동네, 건축 연도 같은 정보이다. y는 실제 매매가격이다.

은행 정기예금 가입 분석에서는 X가 고객의 나이, 직업, 잔액, 대출 여부, 과거 캠페인 기록 같은 정보이다. y는 정기예금 가입 여부이다.

머신러닝은 과거 데이터에 있는 X와 y의 관계를 학습한다.

이 과정을 학습, **Training**이라고 한다.

학습이 끝나면 모델, **Model**이 만들어진다.

모델은 과거 데이터에서 학습한 규칙을 가지고 새로운 X를 받아서 예측값을 계산한다.

이것을 예측, **Prediction**이라고 한다.

여기서는 사람과 머신러닝이 각각 무엇을 하는지 구분해야 한다.

사람은 어떤 문제를 해결할 것인지 정한다. 누구의 어떤 결정을 지원할지 결정한다. 어떤 데이터를 쓰고, 무엇을 예측할지 정의한다.

머신러닝 알고리즘은 주어진 데이터에서 예측에 사용할 패턴과 모델의 매개변수를 학습한다.

그다음 사람이 모델의 결과를 확인한다.

> **사람이 문제를 정의하고, 모델이 데이터에서 규칙을 학습하며, 사람이 그 결과를 검증하고 해석한다.**

이것이 사람과 모델의 역할이 연결되는 구조다.

3. Chapter 1~2: 시세 규칙부터 회귀·과적합·규제까지

Chapter 1에서는 사람이 정한 기존 규칙, 학습 데이터와 평가 데이터의 분리, 예측 시점, 그리고 결정 트리의 기초를 다뤘다.

주택가격 예측 퀘스트의 시세 규칙을 사례로 생각해 보자.

시세 규칙의 변수 후보를 지역·건축 연도에서 품질·지역·면적으로 조정한 사례가 있다.

이때 실제로 수행한 판단은 무엇인가?

사람이 부동산 시장에 관한 지식과 데이터 분석 결과를 이용해서 어떤 정보가 가격 예측에 중요할지 가설을 세우고, 예측 규칙의 구조를 설계하는 일이었다.

이런 사람이 정한 규칙이 머신러닝 모델과 비교하는 기준이 된다.

이것을 **베이스라인, Baseline, 즉 비교 기준선**이라고 한다.

머신러닝 모델이 복잡하더라도 사람이 만든 간단한 규칙보다 예측을 못한다면, 그 복잡한 모델을 선택할 근거는 부족하다.

따라서 모델을 만들기 전에 다음 질문을 던진다.

무엇을 예측하는가? 기존에는 어떻게 예측했는가? 새로운 모델은 기존 방법보다 얼마나 나은가?

이 질문이 먼저이다.

이어서 Chapter 2의 회귀와 모델 복잡도로 연결된다.

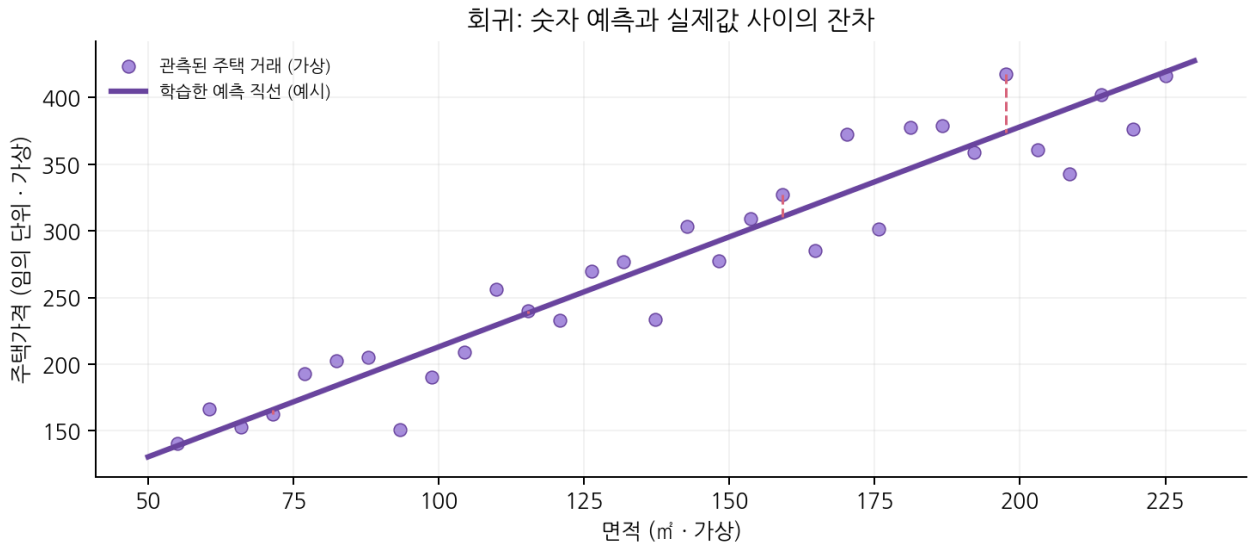
Chapter 2에서는 회귀 모델의 복잡도, 과적합, 규제와 하이퍼파라미터 같은 문제를 다뤘다.

회귀는 앞서 살펴본 것처럼 숫자를 예측하는 문제다.

예를 들어 집의 면적이 커질수록 가격이 올라가는 경향이 있다면, 선형회귀 모델은 그런 관계를 직선 형태의 수학적 규칙으로 표현할 수 있다.

중요한 것은 어떤 직선을 그을 것인가이다.

과거 거래가격과 예측가격의 차이가 작아지도록 선을 정하는 것이다.



개념 도식 | 가상 관측값·예측 직선·잔차의 관계

그런데 이 직선이 모든 집에 정확히 맞을까?

아니다.

집값에는 면적 외에도 지역, 품질, 주택 상태, 거래 시점 등 다양한 요인이 작용하기 때문이다.

그래서 모델이 계산한 예측가격과 실제 거래가격 사이에 차이가 생긴다.

이 차이를 오차 또는 잔차라고 한다. 분석 맥락에 따라 용어가 구분되지만, 지금은 예측이 얼마나 빗나갔는지 나타낸다고 이해하면 된다.

그리고 여러 주택의 오차를 종합하는 평가 지표가 필요하다.

대표적인 것이 RMSE이다. 평균제곱근오차라는 뜻이다.

RMSE는 오차를 제곱한 뒤 평균을 내고 다시 제곱근을 구한다.

왜 제곱할까?

큰 오류에 더 큰 불이익을 주기 위해서다.

예를 들어 실제 가격보다 1만 달러 빗나간 집과 10만 달러 빗나간 집이 있다면, RMSE는 10만 달러 오류를 훨씬 무겁게 반영한다.

집값 예측 컴피티션에서 실제로 사용한 평가 지표가 RMSE다.

> **회귀는 숫자 예측이고, RMSE는 그 숫자가 얼마나 빗나갔는지 평가하는 지표이다. 낮을수록 좋다.**

여기서 한 가지를 더 생각해야 한다.

학습 데이터에 아주 정확하게 맞는 모델이 항상 좋은 모델일까?

아니다.

학습 데이터에만 지나치게 맞아 새로운 주택의 가격은 잘 예측하지 못할 수 있다.

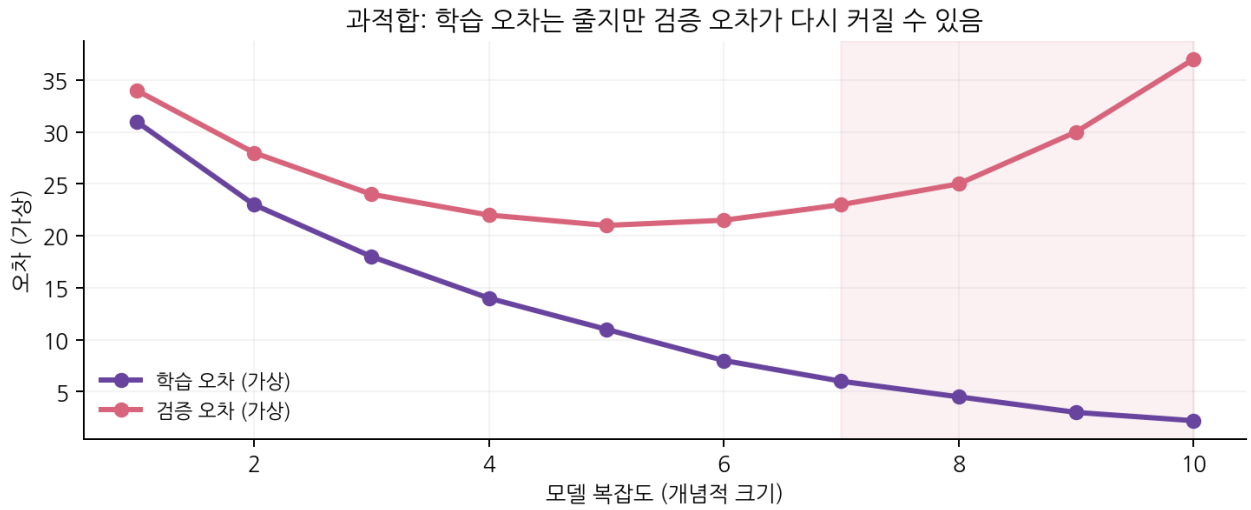
그것을 과적합, Overfitting이라고 한다.

그래서 Ridge와 Lasso 같은 규제 회귀 모델을 배운다.

규제는 모델이 지나치게 복잡해지거나 계수가 극단적으로 커지는 것을 억제하는 장치이다.

Ridge는 계수의 크기를 줄이는 방식으로, Lasso는 일부 계수를 정확히 0으로 만들 수도 있는 방식으로 모델의 복잡도를 관리한다.

이 두 가지는 집값 예측 모델에서도 사용되었다.



개념 도식 | 학습 오차와 검증 오차가 달라질 수 있는 이유

여기까지의 내용을 한 번 더 연결해 보자.

사람은 집값 예측이라는 문제를 정의한다.

모델은 품질, 지역, 면적 같은 입력정보와 과거 매매가격 사이의 관계를 학습한다.

모델이 새로운 집의 가격을 예측하면 RMSE로 오차를 확인한다.

과적합이 있다면 규제나 모델 복잡도 조절을 검토한다.

그런데 여기서 다음 질문이 생긴다.

> **그 RMSE가 과연 새로운 주택에서도 나올 수 있는, 믿을 만한 점수인가?**

이 질문이 Chapter 4의 핵심으로 이어진다.

4. Chapter 3: 분류와 확률·평가 지표

앞에서는 집값처럼 숫자를 예측하는 회귀를 살펴봤다.

은행 마케팅팀의 문제는 다르다.

은행에는 수많은 고객이 있다. 모든 고객에게 똑같이 전화하면 비용이 많이 든다.

그렇다면 어떤 고객에게 전화하는 것이 좋을까?

이것이 분석 의뢰의 출발점이다.

은행은 과거에 전화를 걸었던 고객들의 정보를 가지고 있다. 고객의 나이, 직업, 잔액, 대출 여부, 과거 캠페인 결과, 그리고 실제 정기예금 가입 여부가 기록되어 있다.

실습 데이터는 포르투갈 은행의 정기예금 마케팅 기록이다. 45,211건이 있고, 그중 가입 고객은 약 11.7퍼센트이다.

이 데이터에서 X는 고객의 특성이고, y는 가입 여부이다.

가입했으면 1, 가입하지 않았으면 0이라고 표현한다.

이 문제에서 머신러닝이 하려는 일은 무엇일까?

고객의 과거 정보를 보고, 새로운 고객이 가입할 가능성을 예측하는 것이다.

이것이 분류이다.

> **회귀는 숫자를 예측한다. 분류는 범주를 예측한다.**

Chapter 3에서 학습한 대표 모델은 로지스틱 회귀다.

이름에 회귀가 들어가지만, 로지스틱 회귀는 일반적으로 분류를 수행한다.

입력 변수들을 계산해서 특정 범주에 속할 추정 확률을 만들어 낸다.

예를 들어 어떤 고객의 가입 확률이 0.7이라고 나왔다고 해보자.

이것은 해당 모델이 그 고객에게 70퍼센트의 가입 확률을 추정했다는 뜻이다. 실제로 열 명 중 일곱 명이 반드시 가입한다는 보장은 아니다. 그 확률이 현실에서 잘 맞는지도 별도로 검증해야 한다.

여기서 임계값, Threshold라는 개념이 등장한다.

임계값은 확률을 실제 분류 결과로 바꾸는 기준이다.

예를 들어 임계값을 0.5로 두면 예측 확률이 0.5 이상인 고객을 가입 예상 고객으로 분류할 수 있다.

그런데 임계값을 0.3으로 낮추면 어떻게 될까?

가입할 가능성이 있다고 판단하는 고객의 수가 늘어난다.

실제로 가입할 사람을 더 많이 찾아낼 수 있지만, 가입하지 않을 사람까지 가입할 것으로 판단하는 오류도 증가할 수 있다.

이 때문에 분류 모델은 정확도 하나로 판단할 수 없다.

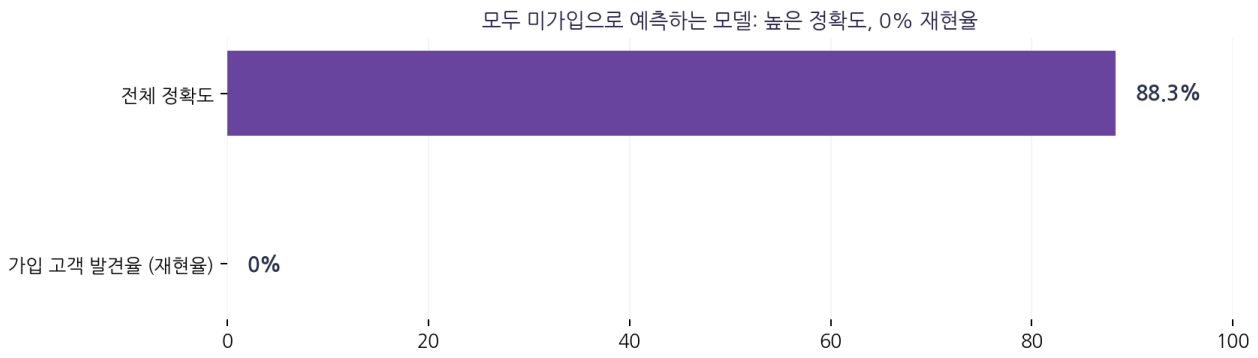
특히 이번 은행 데이터에서는 가입하지 않은 고객이 약 88.3퍼센트이다.

모든 고객을 가입하지 않을 사람이라고 예측하면 어떻게 될까?

정확도가 약 88.3퍼센트나 된다.

그런데 이 모델은 실제 가입 고객을 단 한 명도 찾아내지 못한다.

정확도는 높지만 실제 마케팅 의사결정에는 거의 쓸모가 없는 모델인 셈이다.



개념 도식 | 불균형 데이터에서 정확도만 보면 놓치는 것

그래서 분류에서는 정밀도, 재현율, F1, ROC AUC 같은 지표를 함께 본다.

여기서 두 단어를 구별해야 한다.

> **정밀도, Precision은 가입할 것이라고 예측한 사람들 중 실제 가입한 사람이 얼마나 되는가이다.**

> **재현율, Recall은 실제 가입한 고객들 중 모델이 얼마나 찾아냈는가이다.**

정밀도는 선택한 고객이 실제로 가입할 고객인지에 가깝고, 재현율은 가입 가능 고객을 얼마나 놓치지 않았는지에 가깝다.

ROC AUC는 조금 다르다.

특정 임계값 하나에 고정하지 않고, 모델이 가입 고객을 미가입 고객보다 얼마나 높은 점수로 순위를 매기는지를 종합적으로 평가하는 지표이다.

예를 들어 AUC가 0.773이라면 무작위로 선택한 가입 고객과 미가입 고객 한 쌍에 대해, 가입 고객에게 더 높은 예측 점수를 줄 가능성이 약 77.3퍼센트라는 의미로 이해할 수 있다.

정확도 77.3퍼센트라는 뜻이 아니다.

여기서 전체 구조를 다시 회수해 보자.

주택가격은 회귀였다. 숫자를 예측했고, RMSE로 오차를 측정했다.

은행 가입 여부는 분류였다. 범주 또는 범주에 속할 확률을 예측했고, 정밀도, 재현율, ROC AUC 등으로 평가했다.

하지만 두 문제에는 공통점이 있다.

모델이 높은 점수를 냈다는 사실만으로 그 모델을 믿어서는 안 된다는 것이다.

바로 이 문제가 Chapter 4의 본격적인 주제다.

5. Chapter 4: 데이터 누수와 점수의 신뢰성

Chapter 4의 제목부터 확인하자.

전처리 **파이프라인**과 **데이터 누수**. 부제는 점수를 믿어도 되는가이다.

이 제목이 학습의 방향을 보여준다.

Chapter 1에서 문제를 정의하고, Chapter 2에서 모델을 학습하고 과적합을 생각하고, Chapter 3에서 분류 모델의 점수를 읽었다면, Chapter 4에서는 그 점수 자체를 의심하기 시작한다.

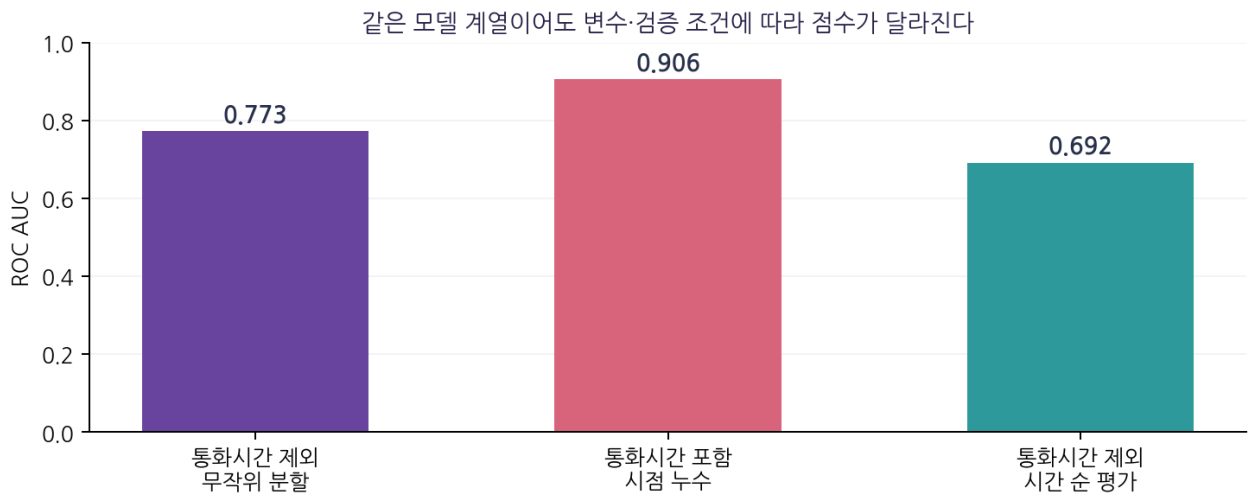
> **학습한 모델의 성능은 과연 실제 운영에서도 재현될 수 있는가?**

이것이 핵심이다.

은행 사례를 다시 살펴보자.

Chapter 3에서 통화 시간을 제외한 로지스틱 회귀 모델의 ROC AUC는 약 0.773이었다.

그런데 통화 시간이라는 변수를 추가하자 AUC가 약 0.906으로 올라간다.



개념 도식 | 교안의 수치: 통화시간 사용 및 분할 조건에 따른 AUC 비교

엄청난 성능 향상처럼 보이다.

이때 분석가는 어떤 판단을 해야 할까?

좋은 변수를 발견했다고 생각할 수도 있다.

하지만 여기서 한 가지 질문을 해야 한다.

> **은행이 이 모델을 사용하는 시점에 통화 시간을 알 수 있을까?**

은행 마케팅팀은 전화를 걸기 전에 누구에게 전화할지 결정하려고 한다.

그런데 통화 시간은 전화를 걸고 난 뒤에야 확정된다.

어떤 고객과 8분 동안 통화했다는 것은 통화가 끝나야 알 수 있다.

따라서 전화를 걸기 전의 고객 선정 모델에 통화 시간을 넣는 것은 실제로 사용할 수 없는 미래 정보를 미리 알고 있다고 가정하는 것이다.

이것이 **데이터 누수**, Data Leakage이다.

여기서 아주 중요한 구분이 있다.

통화 시간과 가입 여부에 강한 관계가 있다는 것은 사실일 수 있다.

하지만 관계가 강하다고 해서 예측에 사용할 수 있는 변수인 것은 아니다.

이것은 통계의 상관관계와도 연결된다.

> **어떤 변수가 결과와 높은 상관관계를 가진다는 사실과 그 변수를 실제 예측 시점에 사용할 수 있다는 사실은 서로 다르다.**

이 차이는 핵심 판단 기준이다.

데이터 누수는 대표적으로 세 가지 방식으로 발생한다.

첫 번째는 **타깃 누수**이다.

정답이 발생한 뒤 만들어지는 정보나 정답의 영향을 받은 정보가 모델에 들어가는 것이다.

은행의 통화 시간이 대표 사례이다.

두 번째는 **전처리 누수**이다.

전체 데이터로 평균이나 표준편차를 계산하고, 그 기준을 이용해 학습 데이터와 평가 데이터를 처리하는 경우이다.

왜 문제가 될까?

평가용 데이터는 아직 만나지 않은 새로운 고객을 대신하는 데이터이다.

그런데 그 고객들의 정보까지 사용해 전처리 기준을 정했다면, 모델을 평가하기 전에 평가 대상의 정보를 일부 들여다본 것이 된다.

세 번째는 **미래 정보 누수**이다.

실제로는 과거 자료를 이용해 미래를 예측해야 하는데, 데이터를 무작위로 섞으면서 미래의 기록이 학습에 들어가는 경우이다.

이 세 가지를 다시 연결해 보자.

> **타깃 누수는 변수의 문제이다. 전처리 누수는 데이터를 처리하는 순서와 범위의 문제이다. 미래 정보 누수는 시간과 분할 방법의 문제이다.**

세 가지 모두 모델의 평가를 실제 운영보다 유리하게 만들 수 있다.

6. 전처리·파이프라인: 평가용 정보를 섞지 않는 구조

데이터를 분석할 때는 결측치를 채우고, 글자로 된 범주를 숫자로 바꾸고, 숫자들의 크기를 조정하는 작업을 한다.

이것을 전처리, Preprocessing이라고 한다.

전처리에서 중요한 것은 기준이다.

결측치를 평균으로 채우려면 어떤 데이터의 평균을 사용할지 결정해야 한다.

숫자를 표준화하려면 어떤 데이터로 평균과 표준편차를 계산할지 결정해야 한다.

지역이나 직업처럼 문자로 기록된 범주를 원핫 인코딩하려면 어떤 범주가 존재하는지 알아야 한다.

그 기준은 어디에서 계산해야 할까?

> **학습 데이터에서만 계산해야 한다.**

여기서 fit과 transform이라는 두 단어가 등장한다.

fit은 데이터를 보고 기준을 학습하는 것이다.

transform은 이미 학습한 기준을 이용해 데이터를 변환하는 것이다.

그래서 학습용 데이터에서 fit하고, 평가용 데이터에는 그 기준으로 transform만 수행한다.

이것을 자동으로 일관되게 처리하기 위해 사용하는 것이 **파이프라인**, Pipeline이다.

파이프라인은 전처리와 모델 학습을 하나의 흐름으로 묶어준다.

그리고 ColumnTransformer는 숫자형 열과 범주형 열에 서로 다른 처리를 적용할 수 있게 해준다.

예를 들어 고객 나이와 예금 잔액에는 스케일링을 적용하고, 고객 직업과 주택대출 여부에는 원핫 인코딩을 적용할 수 있다.

그러면서 그 전처리 기준은 학습 데이터에서만 결정한다.

중요한 것은 **파이프라인**을 썼다는 사실이 아니라, **평가용 정보를 학습에 섞지 않는 구조를 만들었다는 것**이다.

이것이 Chapter 4의 중요한 기술적 목적이다.

전체 흐름으로 다시 연결해 보자.

회귀든 분류든 모델이 예측을 하려면 데이터를 준비해야 한다.

그 데이터를 잘못 준비하면 좋은 모델도 신뢰할 수 없게 된다.

따라서 데이터의 품질뿐 아니라 **데이터를 처리한 과정의 정당성**도 검증해야 한다.

7. 교차검증과 하이퍼파라미터: 점수를 어떻게 믿는가?

이제 모델의 점수를 어떻게 믿을 수 있는지 생각해 보자.

데이터를 학습용과 평가용으로 나누는 이유는 무엇일까?

학습에 사용하지 않은 새로운 데이터에서도 모델이 잘 작동하는지 확인하기 위해서이다.

그런데 데이터 한 번만 나누면 우연이 개입할 수 있다.

어떤 주택들이 평가용에 들어갔는지에 따라 집값 예측 RMSE가 달라질 수 있다.

어떤 은행 고객들이 평가용에 들어갔는지에 따라 ROC AUC가 달라질 수도 있다.

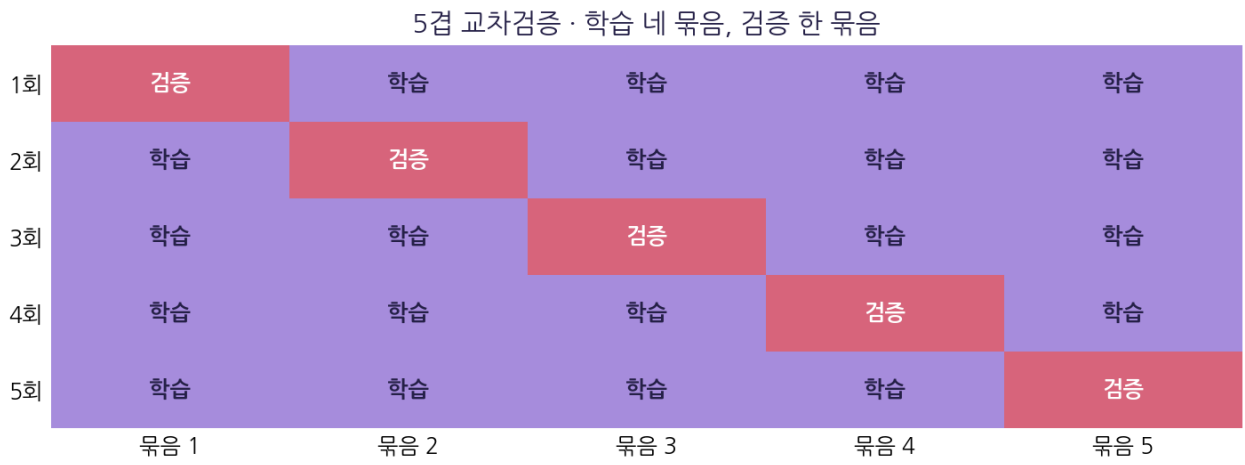
그래서 등장하는 것이 **교차검증**, Cross-Validation이다.

교차검증은 학습용 데이터를 여러 묶음으로 나누고, 번갈아 검증하면서 모델의 성능을 확인하는 방법이다.

대표적으로 5겹 **교차검증**, 5-Fold Cross-Validation이 있다.

데이터를 다섯 묶음으로 나누고, 네 묶음으로 학습한 다음 남은 한 묶음으로 검증한다.

이 과정을 검증 묶음을 바꿔가며 다섯 번 반복한다.



개념 도식 | 5개 fold에서 검증용 묶음을 번갈아 변경

그러면 점수가 다섯 개 나온다.

분석가는 그 점수의 평균뿐 아니라 얼마나 흔들리는지도 본다.

왜일까?

> **분석자가 알고 싶은 것은 특정한 데이터 묶음에서 우연히 잘 맞혔는지가 아니라, 새로운 데이터에서도 비교적 안정적으로 예측할 수 있는지이기 때문이다.**

여기서 모델의 설정을 조정하는 하이퍼파라미터도 연결된다.

결정 트리의 깊이, Ridge의 알파, 로지스틱 회귀의 C 같은 것이 하이퍼파라미터이다.

이 설정들은 학습 알고리즘이 스스로 계산하는 계수와 달리, 모델을 학습시키기 전에 정하거나 탐색할 후보이다.

여러 후보를 비교할 때 최종 테스트 점수를 계속 보면 안 된다.

왜냐하면 테스트 데이터가 사실상 문제 풀이 연습용 데이터가 되어버리기 때문이다.

설정은 학습 데이터 내부의 검증이나 **교차검증**으로 선택하고, 최종 테스트는 모델 선택이 끝난 다음 확인해야 한다.

이 원리를 집값 예측 컴피티션 사례와 연결해 보자.

8. 집값 예측 컴피티션: 실제 프로젝트에서 확인한 것

집값 예측 컴피티션에서는 다양한 모델을 사용했다.

Ridge, Lasso 같은 규제 선형 모델도 사용했고, 그래디언트 부스팅과 XGBoost 같은 트리 기반 모델도 사용했다.

여러 모델의 예측값을 결합하는 블렌딩도 시도했다.

또 결측치 처리, 원핫 인코딩, 이상치 점검, 로그 변환, 예측값 보정도 다뤘다.

처음 모델에서는 테스트 데이터의 결측 처리 방식과 범주형 인코딩이 어긋나면서 예측이 비정상적으로 나오는 경험도 있었다.

이 사례는 전처리 일관성이 왜 중요한지를 보여준다.

모델의 학습 점수가 괜찮아도, 새로운 데이터에 적용하는 전처리가 다르면 예측 결과는 크게 무너질 수 있다.

따라서 학습용과 예측용 데이터에는 동일한 처리 규칙을 적용해야 한다는 사실을 확인할 수 있다.

또 하나의 중요한 검증 문제가 드러났다.

기존 제출에서 리더보드 점수 18,150을 얻었고, 그 과정에서 리더보드 피드백을 모델 설정에 활용했다는 문제를 발견했다.

이것이 바로 Chapter 4의 핵심 문제와 연결된다.

최종 테스트 점수를 반복해서 보고, 그 점수가 더 좋아지도록 설정을 바꿨다면 테스트 데이터가 더 이상 완전히 독립적인 평가 자료가 아니다.

리더보드 점수가 높아졌다는 사실과 새로운 데이터에서도 동일한 성능을 낼 것이라는 주장은 구분해야 한다.

이 점은 아주 중요하다.

> **점수가 좋다는 사실과, 그 점수를 독립적으로 검증했다는 사실은 다르다.**

이에 따라 별도 모델을 학습 데이터 내부의 **교차검증**으로 선택하고, 리더보드 점수에 맞춰 추가 조정하지 않는 절차를 검토했다.

이미 확인한 리더보드 피드백을 없었던 일로 만들 수는 없다. 다만 이후의 모델 선택 절차를 리더보드와 분리하고 그 과정을 투명하게 기록할 수 있다.

이렇게 보면 집값 예측 퀘스트는 단순한 순위 경쟁이 아니었다.

회귀 분석, 모델 비교, 과적합, 전처리, **파이프라인**, 검증, 그리고 **데이터 누수**까지 실제 문제 안에서 모두 경험한 과정이었다.

여기서 반드시 구분할 것이 있다.

> **컴피티션에서 좋은 성적을 내는 것과, 실제 업무에서 믿을 수 있는 예측 시스템을 만드는 것은 서로 관련이 있지만 동일한 목표는 아니다.**

실무에서는 모델이 무엇을 예측했는지뿐 아니라, 그 예측을 어떤 조건에서 검증했는지, 어떤 위험이 남아 있는지, 그 결과로 어떤 결정을 내릴 수 있는지까지 설명해야 한다.

9. 전체 회수: 한 프로젝트 안에서 모든 개념 연결하기

Chapter 1~4를 하나의 분석 과정으로 연결하면 다음과 같다.

1. **문제 정의:** 해결하려는 문제를 정의한다. 주택가격을 예측할 것인지, 고객의 가입 여부를 예측할 것인지 정한다.
2. **X·y 구분:** 데이터에서 입력 정보 X와 정답 y를 구분한다.
3. **베이스라인:** 사람이 만든 규칙이나 단순 모델을 비교 기준선으로 설정한다.
4. **모델 학습:** 적절한 머신러닝 알고리즘을 선택하여 학습한다. 숫자를 예측하면 회귀이고, 범주를 예측하면 분류다.
5. **모델 평가:** 예측 결과를 평가한다. 회귀에서는 RMSE 같은 오차 지표를, 분류에서는 정확도·정밀도·재현율·ROC AUC처럼 목적에 맞는 지표를 본다.

6 **과적합 확인:** 학습 데이터에만 지나치게 맞추어지지는 않았는지 확인한다.

7 **전처리·분할 점검:** 전처리 **파이프라인**과 데이터 분할을 점검한다.

8 **누수·교차검증 점검:** **데이터 누수**가 없는지 확인하고, **교차검증**으로 모델의 성능과 안정성을 비교한다.

9 **결과 해석·보고:** 검증된 결과를 실제 문제의 의사결정 맥락에 맞게 해석하고 보고한다.

> **이 아홉 가지는 각각 별개의 공부가 아니다. 하나의 분석 프로젝트가 시작되어 끝날 때까지 이어지는 작업이다.**

분석 결과를 공유할 때는 코드보다 문제 정의와 의사결정 맥락을 먼저 제시하는 것이 효과적이다.

발표의 설명 순서는 다음 질문을 중심으로 구성할 수 있다.

- 누구의 어떤 문제를 해결하려고 하는가?
- 그 문제를 해결하기 위해 무엇을 예측하려고 하는가?
- 어떤 데이터를 사용했고, 어떤 모델을 선택했는가?
- 모델의 점수를 어떻게 평가했는가?
- 그 점수를 믿을 수 있는가?
- 마지막으로 그 결과가 실제 의사결정에 어떤 의미가 있는가?

이 순서가 유지되면 청중도 분석의 목적부터 결과의 활용 가치까지 전체 흐름을 이해할 수 있다.

이 내용을 AIFFEL 교육과정 전체와도 연결할 수 있다.

AIFFEL 정규교과에서 필수 머신러닝은 데이터 랭글링, 통계적 검정, 인과추론 등을 바탕으로 예측 모델을 만들고 검증하는 구간에 해당한다.

이후에는 군집화와 차원축소, 모델 해석과 SHAP 등을 다루고, SQL과 다른 데이터 분석 프로젝트로 확장된다.

이 내용은 앞으로 수행하는 AI 데이터 분석 프로젝트에도 반복해서 적용되는 공통적인 판단 구조다.

10. 반드시 기억할 다섯 문장

처음의 핵심 원칙으로 돌아가 보자.

핵심 1. 머신러닝의 목적

> 머신러닝은 과거 데이터에서 규칙을 학습해 새로운 데이터를 예측하는 기술이다.

핵심 2. 회귀와 분류

> 회귀는 숫자를 예측하고, 분류는 범주를 예측한다.

핵심 3. X와 y

> X는 예측에 사용하는 입력 정보이고, y는 예측하려는 정답이다. 모델은 학습 데이터에서 X와 y의 관계를 배운다.

핵심 4. 일반화와 과적합

> 학습 데이터에 잘 맞는 것과 새로운 데이터에서도 잘 예측하는 것은 다르다. 그래서 과적합을 점검하고 교차검증을 수행한다.

핵심 5. 점수의 신뢰성

> 점수가 높다고 바로 믿으면 안 된다. 예측 시점, 데이터 누수, 전처리 기준, 평가 방법을 확인해야 한다.

전체 단계를 다시 연결해 보자.

- 문제를 정의한다.
- 데이터를 준비한다.
- X와 y를 정한다.

- 모델을 학습한다.
- 예측값을 얻는다.
- 오차를 측정한다.
- 과적합을 확인한다.
- **데이터 누수**를 점검한다.
- **교차검증**으로 모델을 비교한다.
- 마지막으로 현실에서 활용할 수 있는 판단 근거로 바꾼다.

이것이 Chapter 1~4의 필수 머신러닝 학습 범위다.

그리고 이 전체 과정에서 분석가가 가장 중요하게 지켜야 할 원칙은 하나이다.

> **모델이 계산한 숫자와 그 숫자를 의사결정에 사용해도 된다는 판단은 다르다.**

모델은 예측값을 계산한다.

하지만 그 예측값이 어떤 데이터에서 나왔는지, 어떤 조건에서 검증되었는지, 얼마나 불확실한지, 어떤 위험을 가지고 있는지, 어떤 의사결정을 지원할 수 있는지 설명하는 것은 분석가의 책임이다.

이 전체 구조를 유지할 때 예측 모델을 단순한 점수가 아니라 의사결정 근거로 설명할 수 있다.

최종 인출 질문

> **분석자가 배운 회귀, 분류, 과적합, 파이프라인, 데이터 누수, 교차검증은 결국 하나의 공통된 문제를 해결하기 위해 연결되어 있다. 그 문제가 무엇일까?**

핵심을 한 문장으로 직접 설명해 보자.

이 질문에 자신의 언어로 답할 수 있다면 Chapter 1~4의 개념을 부분이 아니라 전체 구조로 연결한 것이다.

핵심 용어집 · Chapter 1~4

분석 흐름에 따라 핵심 용어를 찾아볼 수 있도록 정리했다. 기술 용어는 본문과 동일하게 선명한 레드로, 핵심 설명은 퍼플 계열로 구분했다.

한국어 개념	영어·코드 용어	정의 및 판단 포인트
머신러닝	Machine Learning	과거 데이터에서 패턴을 학습해 새로운 데이터의 값을 예측하거나 구조를 찾는 방법.
데이터 분석	Data Analysis	데이터를 정리하고 관계·패턴·의미를 해석해 문제와 의사결정에 연결하는 작업.
탐색적 데이터 분석	Exploratory Data Analysis, EDA	데이터의 분포·결측·이상치·변수 관계를 이해하는 초기 분석.
지도학습	Supervised Learning	입력 X와 정답 y가 함께 있는 데이터로 규칙을 학습하는 방식.
비지도학습	Unsupervised Learning	사전에 지정된 정답 없이 데이터의 구조나 유사성을 찾는 방식.
회귀	Regression	주택가격처럼 연속적인 숫자를 예측하는 지도학습 문제.
분류	Classification	가입·미가입처럼 범주나 해당 범주의 확률을 예측하는 지도학습 문제.
군집	Clustering	유사한 특성을 가진 관측치를 그룹으로 묶는 비지도학습 방법.
특성 / 입력 변수	Feature / X	예측 모델에 넣는 정보. 집의 면적·품질·동네 등이 예시.
타깃 / 레이블	Target / Label / y	모델이 예측하려는 실제 정답. 집값이나 가입 여부 등이 예시.
학습	Training	학습 데이터에서 알고리즘이 모델의 매개변수와 규칙을 결정하는 과정.
모델	Model	학습으로 얻은 예측 함수 또는 규칙의 집합.
예측	Prediction	학습된 모델에 새로운 X를 넣어 y를 추정하는 작업.
매개변수	Parameter	모델이 학습 데이터로부터 결정하는 계수·가중치 등.
하이퍼파라미터	Hyperparameter	학습 전에 정하거나 탐색하는 설정. 트리 깊이·Ridge α·로지스틱 C 등.
베이스라인	Baseline	복잡한 모델이 성능을 개선했는지 비교하기 위한 간단한 기준 방법.
선형회귀	Linear Regression	입력 특성과 연속형 정답의 관계를 선형 함수로 표현하는 예측 모델.
로지스틱 회귀	Logistic Regression	특정 범주에 속할 확률을 추정해 주로 분류에 사용하는 모델.
결정 트리	Decision Tree	특성의 조건을 차례로 분기하며 예측하는 모델.

한국어 개념	영어·코드 용어	정의 및 판단 포인트
그래디언트 부스팅	Gradient Boosting	앞선 모델의 오류를 보완하는 예측 모델을 순차적으로 결합하는 앙상블 방법.
XGBoost	Extreme Gradient Boosting	정규화와 효율적 구현 등을 결합한 그래디언트 부스팅 계열 소프트웨어.
블렌딩	Blending	여러 모델의 예측값을 결합하여 하나의 최종 예측으로 만드는 방법.
오차 / 잔차	Error / Residual	예측값과 실제값의 차이. 잔차는 보통 관측값과 적합값의 차이를 뜻함.
RMSE	Root Mean Squared Error	오차 제곱의 평균에 제곱근을 취한 회귀 지표. 큰 오류를 강하게 반영.
과적합	Overfitting	학습 데이터에 너무 맞춰져 처음 보는 데이터에서 예측 성능이 저하되는 현상.
일반화	Generalization	학습하지 않은 새로운 데이터에도 모델이 적절히 작동하는 성질.
규제	Regularization	계수나 모델 복잡도에 제약을 부여하여 과적합을 억제하는 접근.
Ridge	Ridge Regression	계수 크기의 제곱에 벌점을 부여하는 규제 회귀.
Lasso	Lasso Regression	계수 절댓값에 벌점을 부여하며 일부 계수를 0으로 만들 수 있는 규제 회귀.
정확도	Accuracy	전체 사례 중 맞게 분류한 사례의 비율.
정밀도	Precision	양성이라고 예측한 사례 중 실제 양성인 비율.
재현율	Recall	실제 양성 사례 중 양성으로 찾아낸 비율.
F1 점수	F1 Score	정밀도와 재현율의 조화평균.
ROC AUC	Area Under ROC Curve	양성 사례에 음성보다 높은 점수를 매기는 능력을 임계값 전반에서 요약한 지표.
임계값	Threshold	예측 확률을 실제 양성·음성 판정으로 바꾸는 기준값.
전처리	Preprocessing	결측 대체, 인코딩, 스케일 조정 등 모델 입력 전에 수행하는 처리.
결측치	Missing Value	데이터에 관측값이 없거나 비어 있는 상태.
원핫 인코딩	One-Hot Encoding	범주마다 별도 0/1 지시 변수로 변환하는 방법.
스케일링	Scaling	여러 수치형 변수의 크기와 단위를 조정하는 처리.

한국어 개념	영어·코드 용어	정의 및 판단 포인트
fit	fit	주어진 학습 데이터로 전처리 기준 또는 모델 매개변수를 학습하는 동작.
transform	transform	fit으로 정해둔 기준을 사용해 주어진 데이터를 변환하는 동작.
파이프라인	Pipeline	전처리와 모델 학습·예측 단계를 연결해 누수를 예방하도록 돕는 구조.
컬럼 변환기	ColumnTransformer	수치형·범주형 열 등 열 그룹별로 서로 다른 전처리를 적용하는 도구.
데이터 누수	Data Leakage	평가 또는 예측 시점에 이용 불가능한 정보가 학습·모델 선택에 유입되는 문제.
타깃 누수	Target Leakage	정답의 영향을 받은 정보나 정답이 발생한 뒤의 정보가 입력 변수에 들어감.
전처리 누수	Preprocessing Leakage	평가용 데이터까지 사용해 결측 대체·표준화 등 전처리 기준을 학습함.
미래 정보 누수	Temporal Leakage	시간 순서를 무시해 미래 기록을 과거 예측의 학습에 이용함.
학습 세트	Training Set	모델·전처리 기준을 학습시키는 데 사용하는 데이터.
검증 세트	Validation Set	모델·하이퍼파라미터 등을 비교·선택하는 데 사용하는 데이터.
평가 세트	Test Set	모델 선택이 끝난 뒤 최종 일반화 성능을 확인하도록 남겨놓는 데이터.
교차검증	Cross-Validation	학습 데이터 내부에서 검증 묶음을 번갈아 바꿔 성능을 비교하는 방법.
5겹 교차검증	5-Fold Cross-Validation	다섯 묶음 중 한 묶음씩 차례로 검증에 사용하는 교차검증 방식.
리더보드	Leaderboard	컴피티션에서 참가자가 제출한 예측을 채점해 점수와 순위를 보여주는 판.
독립 평가	Independent Evaluation	모델 선택에 쓰지 않은 데이터로 일반화 성능을 확인하는 절차.
의사결정 지원	Decision Support	예측 결과의 근거·위험·한계를 설명해 사람이 더 나은 결정을 하도록 돕는 역할.